



Universidad Andrés Bello

Magíster en Ciencia de Datos e Inteligencia Artificial

Supervivencia en el Titanic: Pipeline Exploratorio de Ingeniería y Selección de Variables

Informe Final — Sumativa 3 (Fase 4: cierre del proyecto)

Curso: MCDI503 — Exploración Inteligente para la Ciencia de Datos
Docente: Sergio Paraíso
Institución: Universidad Andrés Bello (Online)
Grupo: 4
Integrantes: Marcelo Corro, Carolina Cortés,
Pedro Espinoza, Juan Valdebenito
Fecha: Octubre 2026

Notebook de referencia:

mcdi503_f4_sumativo_grupo4.ipynb

Repositorio: <https://github.com/kingdom0fbullshit/proyecto-grupo4-mcdi503>

Este informe sintetiza el pipeline implementado en el notebook adjunto.
Las referencias con § corresponden a las secciones numeradas del notebook.

I. Título del avance y foco del pipeline final

Supervivencia en el Titanic: pipeline exploratorio de ingeniería y selección de variables.

Este informe cierra el proyecto, cuyo foco analítico es identificar qué factores se asocian a la supervivencia de los 891 pasajeros del dataset Titanic (seaborn; Waskom, 2021). La Fase 4 implementa un pipeline reproducible que transforma las variables relevantes, crea variables derivadas y selecciona de forma preliminar las características para una etapa de modelamiento, a partir de los hallazgos de las fases anteriores.

II. Contexto del proyecto y objetivo del cierre

Siguiendo la metodología del curso (Paraíso, 2026), en las Fases 1 a 3 se diagnosticó la calidad de los datos (869 valores nulos, 107 duplicados, columnas redundantes), se limpiaron e integraron con una tabla de puertos publicada en el repositorio del proyecto y se identificaron, mediante análisis univariado y bivariado, los patrones de supervivencia: el sexo (74,2% de mujeres frente a 18,9% de hombres), el gradiente por clase, la interacción sexo $\times$ clase, la relación no lineal del tamaño familiar y la asimetría extrema de la tarifa.

Objetivo del cierre: convertir esos hallazgos en un conjunto reducido, interpretable y trazable de características, documentando cada transformación, variable creada y decisión de selección junto con su efecto sobre los datos. **Relación con el análisis previo:** el notebook es autocontenido; la función `preparar_base()` reaplica la limpieza de la Sumativa 2 sobre las fuentes originales (891 $\times$ 18, sin nulos) y una tabla de ocho hallazgos del EDA (H1–H8) justifica cada decisión posterior (§III). **Alcance:** el trabajo es exploratorio y de preparación; no se entrenan modelos. **Valor para la toma de decisiones:** permite priorizar los factores con mayor peso explicativo y deja un dataset listo para construir un clasificador interpretable.

III. Transformaciones y normalizaciones aplicadas

La Tabla 1 resume las transformaciones (§IV); cada una se justifica con un hallazgo del EDA y se acompaña de la evidencia de su efecto (Kuhn y Johnson, 2019; Zheng y Casari, 2018).

Tabla 1: Transformaciones y normalizaciones aplicadas

Variable	Operación	Hallazgo que la motiva	Efecto en los datos
<code>fare</code> $\rightarrow$ <code>fare_log</code>	$\log(1 + x)$	H1: asimetría 4,79 y 116 outliers que son tarifas reales	Asimetría 0,39; curtosis 33,4 $\rightarrow$ 0,98; outliers 116 $\rightarrow$ 31; r con <code>survived</code> 0,26 $\rightarrow$ 0,33
<code>age</code> , <code>fare_log</code> $\rightarrow$ <code>_z</code>	<code>z-score</code>	H2: escalas distintas (0,42–80 años vs. 0–6,2)	Media 0 y desviación 1; la forma no cambia (asimetría 0,53 y 0,39)
<code>sex</code> , <code>embarked</code> , <code>pclass</code> , <code>age_group</code> , <code>fare_bin</code>	Binaria, <i>one-hot</i> y ordinal	H3–H4: nominales sin orden; <code>pclass</code> con gradiente monótono (63,0 / 47,3 / 24,2%)	Todas numéricas, con correspondencia 1 a 1; supervivencia monótona por <code>fare_bin</code> (19,7% $\rightarrow$ 58,1%)
<code>family_size</code> $\rightarrow$ <code>family_cat</code>	Tramos 0 / 1–3 / ≥ 4	H5: relación no lineal (forma de U invertida)	Solo 30,4 %, pequeña 57,9 %, grande 16,1 %; $r = 0,02 \rightarrow V$ de Cramér = 0,29




Figura 1: Efecto de la transformación logarítmica de fare (a, b) y supervivencia según la variable derivada sexo_clase (c).

La transformación logarítmica se aplicó antes de estandarizar porque el *z-score* solo cambia la ubicación y la escala, no la forma (Figura 1a–b). Los 15 pasajeros con fare = 0 quedan aislados en 0 y siguen identificados con fare_cero_flag. Los parámetros de escalado se calcularon con todo el dataset con fines exploratorios; en el pipeline se ajustan solo con el conjunto de entrenamiento (sección VI).

IV. Variables derivadas o creadas

Se crearon cinco variables nuevas (§V), cada una vinculada a un hallazgo y con evidencia de su comportamiento (Tabla 2).

Tabla 2: Variables derivadas o creadas

Variable	Origen y regla de construcción	Valor analítico esperado	Evidencia
sexo_clase	sex + pclass (6 categorías)	Representa la interacción sexo × clase (H4), que un modelo aditivo no captura	De 13,5 % (hombre_3) a 96,8 % (mujer_1); $V = 0,63$ (Figura 1c)
es_nino	1 si age ≤ 12	Efecto de la edad concentrado en la niñez: «mujeres y niños primero» (H2)	Hombres: 16,3 % (adultos) vs. 56,8 % (niños)
tarifa_pp_log	$\log(1 + \text{fare}/(\text{family_size} + 1))$	Gasto individual, independiente del tamaño del grupo que comparte el boleto (H1)	r con family_size: 0,38 → -0,17
deck_conocido	1 si deck está registrado en df_raw	Rescata información de deck (77 % de nulos) sin imputar (H7)	Supervivencia 67,0 % vs. 29,9 %
edad_imputada	1 si age era nula en df_raw	Los faltantes de edad no son aleatorios (H7; Little y Rubin, 2019)	Supervivencia 29,4 % vs. 40,6 %

V. Selección preliminar de características

Se evaluaron 28 variables con cinco criterios explícitos (§VI; Guyon y Elisseeff, 2003): **C1** relevancia (correlación punto-biserial, V de Cramér e información mutua con survived), **C2** redundancia (Spearman $|\rho| \geq 0,7$ y $VIF > 5$), **C3** interpretabilidad, **C4** consistencia y calidad, y **C5** sentido

operativo y fuga de información. La Tabla 3 sintetiza las decisiones; la justificación de cada una de las 28 variables está en la tabla de decisión del notebook (§VI.4).

Tabla 3: Selección preliminar de características

Decisión	Variables	Justificación (criterios)
Priorizar (3)	sex_male, pclass, fare_log_z	Mayor asociación individual ($r = -0,54$; $V = 0,34$; $r = 0,33$), interpretables y sin redundancia ($VIF \leq 3,4$) (C1, C2, C3)
Conservar (5)	sexo_clase, family_cat, age_z, es_nino, deck_conocido	Interacción más asociada ($V = 0,63$), no linealidad familiar ($V = 0,29$), edad con relación no lineal (información mutua 0,044 frente a $r = -0,06$), efecto de la niñez en hombres y faltante informativo ($V = 0,32$; $VIF 2,2$) (C1, C3, C4)
Revisar (4)	tarifa_pp_log, embarked, edad_imputada, fare_cero_flag	Redundante con fare_log ($r = 0,82$; $VIF 25$), asociación confundida con la clase ($V = 0,17$), asociación débil ($V = 0,09$) y solo 15 casos (C1, C2, C4)
Descartar (16)	sex, age, fare, sibsp, parch, family_size, viaja_solo, age_group, fare_bin, puerto, pais, lat, lon, deck, survived_label	Reemplazadas por su versión transformada; colinealidad perfecta (sibsp, parch: VIF infinito); información contenida en family_cat; repiten variables continuas (ρ de 0,89 y 0,97) o a embarked (V idéntica = 0,171) (C1, C2) 77,2% de nulos (C4) y fuga de información: repite el objetivo (C5)

Al eliminar las variables redundantes, el VIF máximo baja de valores infinitos a 3,1 (3,36 en el conjunto final, §VIII). La selección es preliminar: las variables en revisión se evaluarán con validación cruzada en la etapa de modelamiento.

VI. Documentación reproducible del pipeline

- **Registro:** cada decisión se registró con registrar() al ejecutarse (42 decisiones con motivo y efecto) y se consolidó en log_decisiones y en una tabla acción → efecto (§VII.1, §VII.3).
- **Pipeline de scikit-learn** (Pedregosa et al., 2011): FunctionTransformer + ColumnTransformer que reproduce exactamente los pasos manuales y se ajusta solo con entrenamiento (partición estratificada 80/20, 712/179 filas), sin usar información del conjunto de prueba (§VII.2).
- **Organización:** diez secciones según la estructura de la evaluación, convenciones de nombres (_log, _z, _ord, _cat, indicadores 0/1), interpretación con cifras tras cada resultado, versiones impresas, semilla fija y ejecución completa.
- **Correspondencia:** los apartados III a VIII del informe remiten a las secciones IV a IX del notebook; la presentación sigue la misma secuencia, cifras y gráficos.

VII. Resultados del pipeline y valor analítico del cierre

El resultado es df_modelo (§VIII): 891 filas, 15 características y la variable objetivo. Respecto del inicio (df_raw), los valores nulos pasan de 869 a 0, las columnas no numéricas de 7 a 0, la asimetría máxima de las variables continuas de 4,79 a 0,53 y el rango máximo entre columnas de 512,3 a 6,4, sin multicolinealidad severa (VIF máximo 3,36). Las características finales conservan las asociaciones del EDA: el sexo masculino y hombre_3 se asocian negativamente con la su-

pervivencia, y `mujer_1`, `mujer_2`, la tarifa y la cubierta registrada, positivamente. **Valor analítico:** el cierre confirma que la interacción `sexo × clase` es el factor más asociado a la supervivencia, seguida del sexo, la clase, la tarifa, la niñez y el tamaño familiar, y entrega un insumo trazable (exportado a CSV) para un modelo base de regresión logística, comparable con modelos de árboles y con la línea base de 61,6 % de exactitud.

VIII. Decisiones metodológicas, supuestos y limitaciones

Decisiones metodológicas: transformar antes de eliminar (ningún outlier se eliminó); aplicar la transformación logarítmica antes del *z-score*; recodificar en lugar de forzar relaciones lineales; seleccionar con filtros univariados y bivariados complementados con medidas de redundancia; y encapsular todo en un pipeline ajustable solo con entrenamiento.

Supuestos (§IX.2): (S1) los faltantes de `age` son MAR respecto de `pclass` y `sex`; (S2) los cortes de `family_cat`, `es_nino` y los tramos representan cambios de comportamiento observados en el EDA; (S3) la tarifa corresponde al grupo familiar declarado; (S4) las 107 filas duplicadas son pasajeros distintos; (S5) las tarifas iguales a 0 son valores reales; y (S6) imputar `embarked` con la moda tiene un impacto despreciable.

Limitaciones (§IX.3): (L1) la selección evalúa cada variable por separado y no su aporte conjunto en un modelo; (L2) la clase se relaciona con casi todas las variables (`deck_conocido` se registra en 81 % de la 1.^a clase y en 2,4 % de la 3.^a), por lo que parte de las asociaciones puede ser un efecto indirecto de la clase, y ninguna es causal; (L3) la imputación reduce la variabilidad de la edad y deja a los niños sin edad registrada como `es_nino = 0`; (L4) hay grupos con pocos casos (62 en `family_cat = grande`, 69 niños) y la muestra cubre 891 de cerca de 2.200 personas a bordo; y (L5) `sexo_clase` es colineal por construcción con `sex_male` y `pclass`, por lo que en un modelo lineal debe usarse como interacción o en reemplazo de ellas.

IX. Bibliografía

- Guyon, I., y Elisseeff, A. (2003). An introduction to variable and feature selection. *Journal of Machine Learning Research*, 3, 1157–1182.
- Kuhn, M., y Johnson, K. (2019). *Feature engineering and selection: A practical approach for predictive models*. CRC Press. <https://doi.org/10.1201/9781315108230>
- Little, R. J. A., y Rubin, D. B. (2019). *Statistical analysis with missing data* (3.^a ed.). Wiley.
- Paraíso, S. (2026). *Material del curso MCDI503 — Exploración Inteligente para la Ciencia de Datos* [Material de curso]. Universidad Andrés Bello, Online.
- Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., y Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.
- Waskom, M. L. (2021). seaborn: Statistical data visualization. *Journal of Open Source Software*, 6(60), 3021. <https://doi.org/10.21105/joss.03021>
- Zheng, A., y Casari, A. (2018). *Feature engineering for machine learning: Principles and techniques for data scientists*. O'Reilly Media.